1. Контекст — TrustScore AI для кредитного аналітика

Користувач: кредитний аналітик банку. Рішення: схвалити заявку, відхилити або передати на ручний розгляд.

Вхід: анкетні й фінансові дані позичальника — без захищених ознак (стать, сімейний стан, іноземець).

Вихід: P(дефолту), рекомендація, невизначеність, фактори для обґрунтування; для нетипових заявок — відповідь правила.
Дані: Statlog German Credit, 1 000 заявок, 30 % дефолтів; тренування 700 / тест 300 (ЛР №1–3, DVC).

Мета з ML Canvas (ЛР №1): менше втрат від неповернених кредитів без дискримінації за статтю.

Ціна помилок (ЛР №3): FN — видали неплатникові, 1 500 DM; FP — відмовили надійному, 150 DM.

2. Конфлікт — межі Non-ML правила

Правило ЛР №1 («рахунок < 0 DM або строк > 24 міс. при заощадженнях < 100 DM»): 196 DM втрат на заявку на тесті.
Воно ловить лише 56 з 90 дефолтів (34 пропущено × 1 500 DM) — за 10:1 ціною помилок пропуски домінують.

ЛР №2–3 показали: розширення ознак чужими даними (скарги CFPB, платежі Home Credit) не допомагає,

а витік даних дає хибні +0.10 AUC (p = 0.005). Потрібна герметична модель на анкеті з контролем витоку й OOD.

Модель ЛР №3 (RF, class_weight 1:10, поріг 0.50): 95.5 DM/заявку на тесті, ROC-AUC 0.754.

Але: вона схвалює лише ~16 % заявок — бізнес-оптимум за цієї матриці втрат дуже обережний.

3. Вирішення — архітектура PoC

Модель → ONNX (RandomForest + відбір у графі); препроцесор ЛР №1 (імпутер, one-hot, відношення) — поза графом, skops.
MLflow Registry: v1 (модель) → v2 (+ OOD-детектор, сегменти), аліас @champion; відкат = перепризначення аліасу.
FastAPI: контракт Pydantic v2 (межі з домену, strict, захищені ознаки → 422); інференс у threadpool; SQLite-журнал і /v1/feedback.
OOD-fallback: GMM-густина у просторі моделі (8 компонент PCA, 93% дисперсії); нижче 1-го перцентиля → відповідь правила.
Трек 4C «Карта даних»: 10 сегментів заявників із метриками й топ-ознаками; зони обмеженої довіри в Model Card.
XAI: SHAP (TreeExplainer, interventional) + LIME на сервері; дашборд Streamlit лише через HTTP.

4. Перевірка — інтервали, паритет, тести, справедливість

Вкладена CV ЛР №3 (5 фолдів): ROC-AUC 0.745 (0.69–0.80), втрати 99.5 DM (92–107).

Тест 300: ROC-AUC 0.754, F1 0.50; паритет ONNX max|Δp| = 1.4e-07, 0 змінених міток.

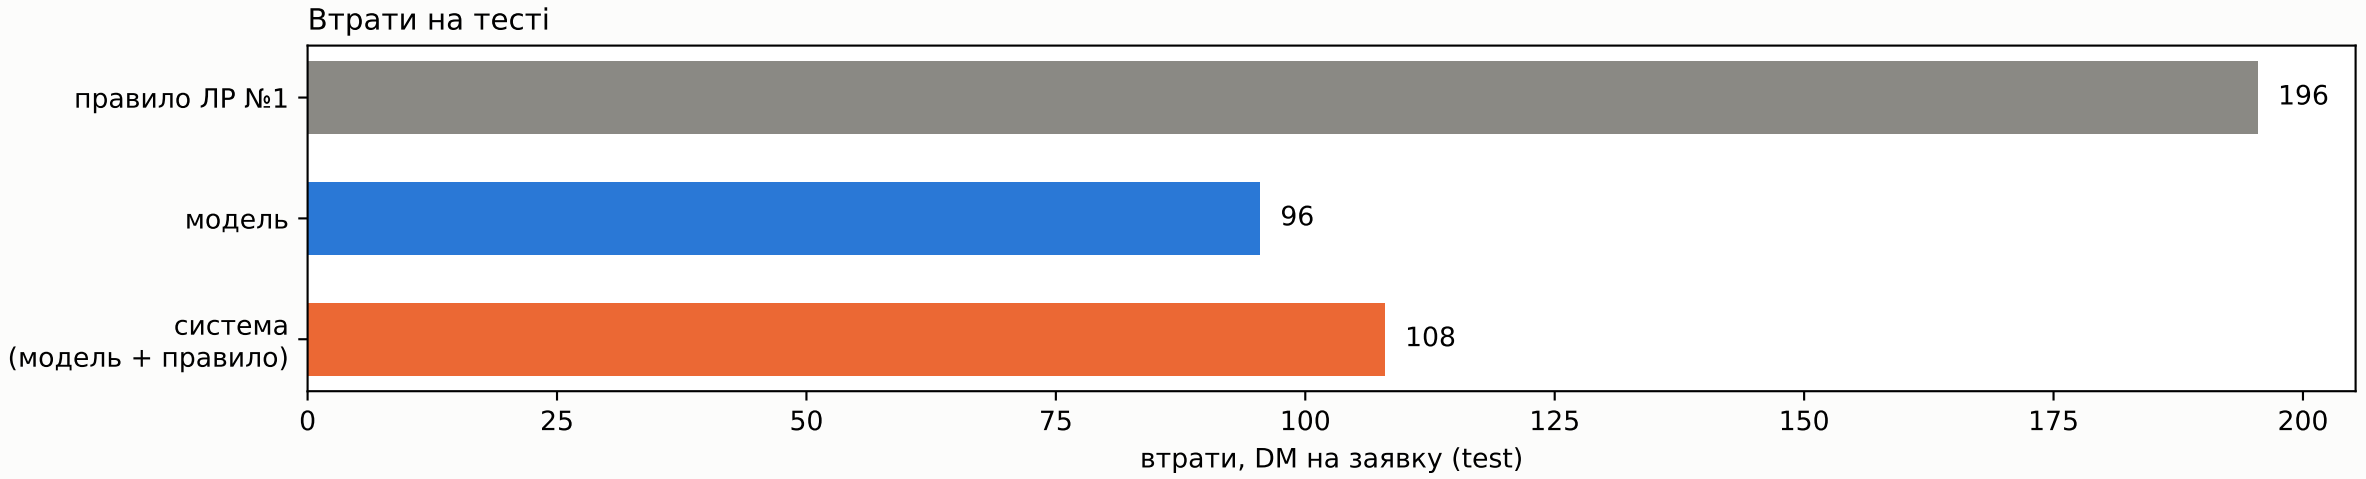
Автотести: паритет + 8 сценаріїв API + 2 треку (pytest); затримка /v1/predict p95 = 33 мс.

OOD: fallback на тесті 3.7%, штучних OOD виявлено 100%.

Справедливість (стать, система): DPR 0.71 [0.36; 1.20], EOR 0.91 — правило 4/5 не підтверджено,

інтервал містить 1: мало схвалень (13 % жінок, 18 % чоловіків). Конфлікт бізнес-оптимуму і 4/5 зафіксовано.

Пояснення: fidelity сурогату R^2 = 0.92; стабільність SHAP (Спірмен топ-5) 0.99 — діагностика, не доказ.



run_id a38a6e7c4aae4ad9919af5488243e3f6 · v2 · test n=300 · валюта DM

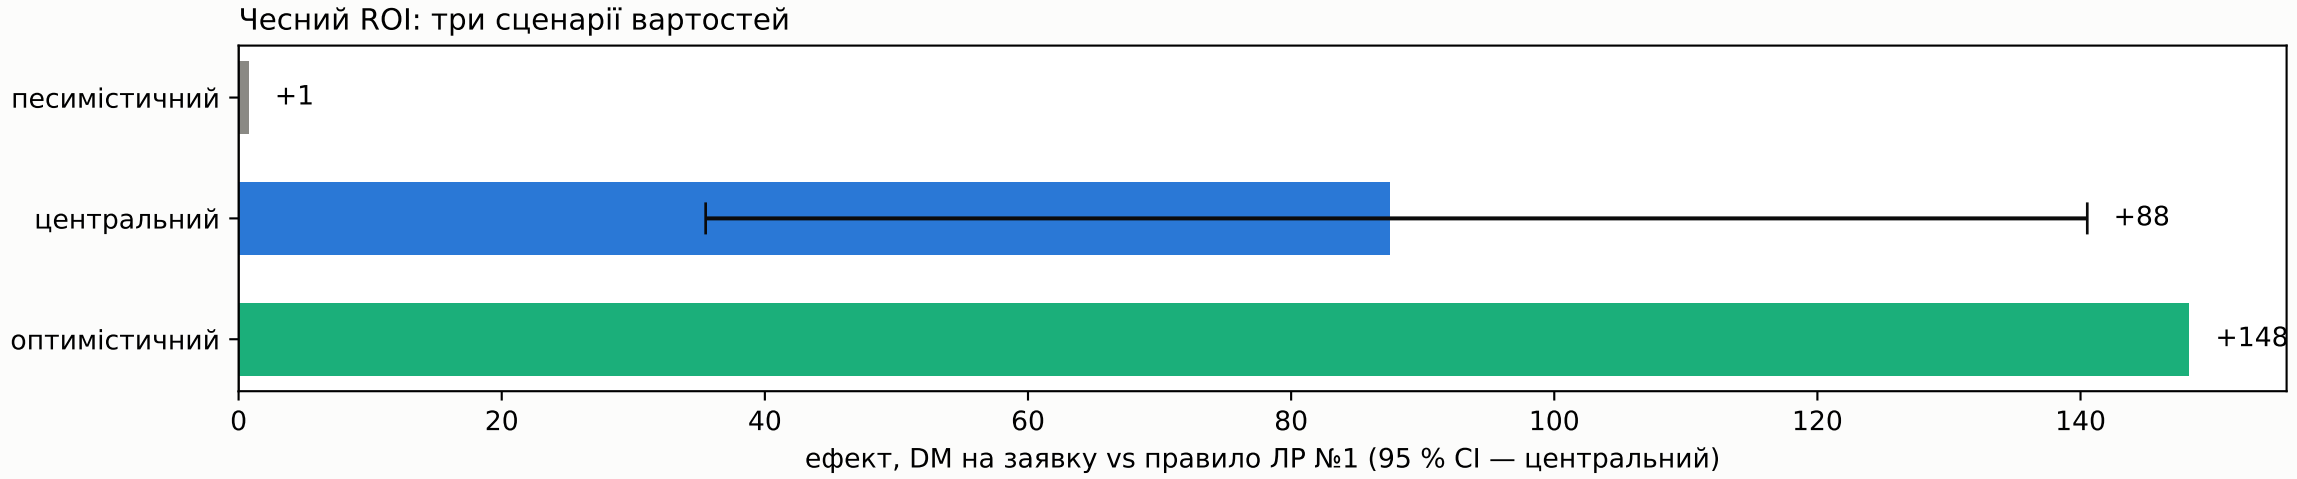
5. Вплив — чесний ROI, OOD, трековий модуль, регуляторика

Ефект = втрати(правило) − втрати(система), той самий тест: центральний +88 DM/заявку (95 % CI +36…+141),

песимістичний +0.8 (C01×1.5, C10×0.6), оптимістичний +148 (C01×0.7, C10×1.3). Припущення — з матриці ЛР №3.

Ціна: схвалення падає з 64 % (правило) до ~16 % — бінарне рішення за 10:1 неадекватне; наступний крок — ціноутворення за ризиком.
OOD: 11 з 300 нетипових заявок отримали відповідь правила; на них якість детектора не оцінено — міток OOD немає.

Трек 4C: аналітик бачить, чи типовий позичальник і наскільки точна модель для його сегмента; зони обмеженої довіри — у Model Card.
EU AI Act: кредитний скоринг — Annex III (високий ризик), обов'язки з 2 грудня 2027 р.; остаточне рішення — за людиною.



run_id a38a6e7c4aae4ad9919af5488243e3f6 · v2 · test n=300 · валюта DM